

Wikipedia Pulse

Détection d'événements mondiaux émergents via le flux d'éditions Wikipedia

Auteur Amidou Soro
Institution ISEP Paris — module Big Data
Date Juin 2026
Dépôt github.com/AmidNova/wikipedia-pulse
Stack Kafka · Spark · Airflow · Elasticsearch · Kibana · scikit-learn · Docker

Le constat


Les contributeurs Wikipedia réagissent aux événements avant le grand public. Lors des attentats de Londres du 7 juillet 2005, l'article correspondant a enregistré 2857 éditions en 24 heures alors que les pageviews n'avaient pas encore augmenté. Ce décalage est reproductible : sur les événements majeurs, le délai moyen entre pic d'éditions et pic de consultation se situe entre 12 et 48 heures.

Le projet croise deux signaux complémentaires. Les éditions Wikipedia (lead indicator, disponibles en temps réel) précèdent les statistiques de pageviews quotidiennes (lag indicator, publiées à J+1 par l'API Wikimedia Analytics). Un article dont le ratio éditions/pageviews dévie statistiquement de la norme sur le corpus du jour est un candidat à un événement en cours.

Architecture

Le pipeline suit un pattern Lambda : chemin *stream* pour les éditions (Wikimedia EventStreams → Kafka → Airflow) et chemin *batch* pour les pageviews (Wikimedia Analytics API → Airflow directement). L'ensemble est orchestré par un DAG Airflow composé de six tâches atomiques et rejouables indépendamment.

Les données transitent par trois couches : *raw/* (ingestion brute, NDJSON et JSON), *formatted/* (normalisation en Parquet snappy), *usage/* (résultats agrégés prêts pour l'indexation).



Décisions techniques

Découplage SSE/Airflow par Kafka. Le flux Wikimedia EventStreams est continu ; Airflow s'exécute périodiquement en batch. Sans tampon, les éditions émises entre deux runs seraient perdues. Un producer Kafka écoute le flux en permanence et publie chaque événement dans le topic wikipedia-edits. La tâche Airflow `edits_stream_to_raw` consomme ce topic à son propre rythme, sans couplage temporel avec le producer.

Détection d'anomalies non supervisée. L'absence de données labellisées exclut les approches supervisées. L'Isolation Forest est entraîné sur le corpus du jour (features : `edit_count`, `unique_editors`, `total_edit_size`, `edit_velocity`). Il attribue un `anomaly_score` négatif aux articles statistiquement isolés dans cet espace. Le paramètre de contamination est fixé à 0,10. Le modèle est recalculé à chaque run du DAG, sans phase d'entraînement séparée.

Score de tendance.

$$\text{trending_score} = \frac{\text{edit_count} \times \text{unique_editors}}{\log(\text{pageviews} + 2)}$$

Le numérateur pondère le volume d'éditions par le nombre d'éditeurs distincts, ce qui filtre les modifications répétées d'un seul compte. Le dénominateur normalise par l'audience déjà acquise : un article très lu accumule mécaniquement des éditions sans être nécessairement émergent.

Résultats

Sur la fenêtre d'analyse (mai–juin 2026), le pipeline a traité 4 808 articles et 5 368 éditions humaines (bots exclus via le flag `bot=false` du flux SSE). L'Isolation Forest a classé 365 articles comme émergents, soit 7,6 % du corpus, ce qui est cohérent avec le paramètre de contamination à 10 %.

Métrique	Valeur
Articles analysés	4 808
Éditions humaines collectées	5 368
Événements émergents détectés	365 (7,6 % du corpus)

Le croisement éditions/pageviews fait ressortir plusieurs patterns. Certains articles accumulent des éditions sans figurer dans les pageviews top-1000 : ce sont les candidats “scoop”, détectés avant leur diffusion grand public. La feature `first_language` révèle quelle communauté linguistique édite un article en premier, ce qui permet de tracer l'origine géographique d'un événement. Le `trending_score` segmente le corpus en trois comportements : émergent (éditions en hausse, pageviews faibles), viral (pageviews en hausse, éditions stabilisées), niche (éditions stables, pageviews faibles sur la durée).

Limites & suite logique

Le principal biais du prototype est le volume de données. En mode test, le producer Kafka ne tourne que pendant les sessions de collecte. En production, il devrait fonctionner 24 h/24 pour que l'Isolation Forest dispose d'une distribution quotidienne représentative.

La jointure éditions/pageviews repose sur la correspondance exacte des titres entre langues, ce qui exclut les articles dont le titre varie selon la locale. L'utilisation des identifiants Wikidata résoudrait ce problème et rendrait le matching cross-lingue robuste.

Un déploiement cloud (AWS ou GCP) permettrait un fonctionnement continu et un dashboard Kibana accessible en temps réel depuis n'importe quel navigateur.